

Slides licensed under Creative Commons
Attribution [CC-BY 4.0](https://creativecommons.org/licenses/by/4.0/), unless noted otherwise

Image processing

Lecture 4

Filters – Part B

Assaf B. Spanier



עיבוד תמונה – שיעור 4 (שבוע 6)

1. חזרה

- 1. Convolutions \ קונבולציה
- 2. מה עושים עם קונבולציה – חלק א'
 - 1. Blur
 - 1. אחיד
 - 2. גאוסיאני
 - 3. Bi-lateral filter
 - 2. Edges
 - 1. First derivative



עיבוד תמונה – שיעור 4 (שבוע 6)

1. חזרה

1.1 Convolutions \ קונבולציה

2. מה עושים עם קונבולציה – חלק א'

1.1 Blur

1. אחיד

2. גאוסיאני

3. Bi-lateral filter

2. Edges

1. First derivative



0	0	0	0	0	0
0	105	102	100	97	96
0	103	99	103	101	102
0	101	98	104	102	100
0	99	101	106	104	99
0	104	104	104	100	98

Image Matrix

Kernel Matrix		
0	-1	0
-1	5	-1
0	-1	0

320				

Output Matrix

$$\begin{aligned} &0 * 0 + 0 * -1 + 0 * 0 \\ &+ 0 * -1 + 105 * 5 + 102 * -1 \\ &+ 0 * 0 + 103 * -1 + 99 * 0 = 320 \end{aligned}$$

Convolutions with zero padding



עיבוד תמונה – שיעור 4 (שבוע 6)

- 1. חזרה
 - 1. Convolutions \ קונבולציה
 - 2. מה עושים עם קונבולציה – חלק א'
- 1. Blur
 - 1. אחיד
 - 2. גאוסיאני
 - 3. Bi-lateral filter
- 2. Edges
 - 1. First derivative



עיבוד תמונה – שיעור 4 (שבוע 6)

1. חזרה

1. Convolutions \ קונבולציה

2. מה עושים עם קונבולציה – חלק א'

1. Blur

1. אחיד

2. גאוסיאני

3. Bi-lateral filter

2. Edges

1. First derivative



עיבוד תמונה – שיעור 4 (שבוע 6)

1. חזרה

1. Convolutions \ קונבולציה

2. מה עושים עם קונבולציה – חלק א'

1. Blur

1. אחיד

2. גאוסיאני

3. Bi-lateral filter



2. Edges

1. First derivative



"מילים נרדפות"

Smoothing with box filter	Smoothing with Gaussian filter
Smoothing with uniform filter	Smoothing with Gaussian
Blur with box filter	Blur with Gaussian
Blur with uniform filter	Blur with Gaussian filter
Averaging with uniform filter	Averaging with Gaussian filter
Blur with box filter	Blur with Gaussian filter
box filter	Smoothing.
Smoothing.	Averaging
Averaging	Blurring.
Blurring	Gaussian Blurring
homogeneous	




מיצוץ
3X3

1	1	1
1	1	1
1	1	1

1	1	1	1	1
1	1	1	1	1
1	1	1	1	1
1	1	1	1	1
1	1	1	1	1

מיצוץ
5X5



מיצוץ
9X9

1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1



קוד: מיצוע Blur/

```
import cv2
import numpy as np
from matplotlib import pyplot as plt

img = cv2.imread('opencv_logo.png')

kernel = np.ones((5,5),np.float32)/25
dst = cv2.filter2D(img,-1,kernel)

plt.subplot(121),plt.imshow(img),plt.title('Original')
plt.xticks([], plt.yticks([]))
plt.subplot(122),plt.imshow(dst),plt.title('Averaging')
plt.xticks([], plt.yticks([]))
plt.show()
```



קוד: מיצוע / Blur

```
import cv2
import numpy as np
from matplotlib import pyplot as plt

img = cv2.imread('opencv_logo.png')


blur = cv2.blur(img,(5,5))

plt.subplot(121),plt.imshow(img),plt.title('Original')
plt.xticks([], plt.yticks([]))
plt.subplot(122),plt.imshow(blur),plt.title('Blurred')
plt.xticks([], plt.yticks([]))
plt.show()
```


Gaussians




$$G(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}}$$




2d Gaussian



$$g(x, y) = \frac{1}{2\pi\sigma^2} \cdot e^{-\frac{x^2+y^2}{2\sigma^2}}$$




מיצוּע
אחיד
29x29




מיצוּע
גאוסיאני
29x29



מיצוץ
אחיד
29x29



מיצוץ
גאוסיאני
29x29



מיצוץ
Bi-lateral
29x29





עיבוד תמונה – שיעור 4 (שבוע 6)



1. חזרה

1. Convolutions \ קונבולציה

2. מה עושים עם קונבולציה – חלק א'

1. Blur

1. אחיד

2. גאוסיאני



3. Bi-lateral filter

2. Edges


1. First derivative

קצוות תמונה



קצוות של
תמונה סינטטית



קצוות מאפייני
אובייקטים




קצוות שאינם מאפיינים
אובייקטים






מקורות אפשריים לקצוות



[Cornelia Fermüller](#)

First derivative



דמיינו את התמונה כנוף. **הנגזרת הראשונה** היא כמו להסתכל על שיפוע הגבעות והעמקים. היכן שהשיפוע משתנה מאוד, זה אומר לך שמשוהו מעניין קורה, כמו המעבר מאזור בהיר לאזור חשוך.

בתמונות, **הנגזרת הראשונה** מצוינת במציאת קצוות. הוא מצביע על המקומות שבהם הצבעים או הבהירות משתנים בפתאומיות, ומדגיש את הקצוות של אובייקטים בתמונה. זה כמו לתאר את החלקים החשובים.

■ Recall

■ We could approximate this as


$$\frac{\partial}{\partial x} f = \lim_{\varepsilon \rightarrow 0} \left(\frac{f(x + \varepsilon, y) - f(x, y)}{\varepsilon} \right) \quad \frac{\partial}{\partial x} f \approx \frac{f(x_{i+1}, y) - f(x_{i-1}, y)}{2 \cdot \Delta x}$$



$$\frac{\partial f}{\partial x} \approx f(x+1, y) - f(x, y)$$

$$\frac{\partial f}{\partial y} \approx f(x, y+1) - f(x, y)$$

נגזרת ראשונה של תמונה רועשת





תזרה

[illegible]

Sobel filter! Smooth & derivative




$$\frac{1}{2} \times \left(\begin{bmatrix} -1 & 0 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \right)$$



1	0	-1
2	0	-2
1	0	-1


נגזרת של הגאוסיאן בדו-ממד

2D edge detection filters



Gaussian

$$\begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$$



derivative of Gaussian (x)

$$\begin{bmatrix} +1 & 0 & -1 \\ +2 & 0 & -2 \\ +1 & 0 & -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \begin{bmatrix} +1 & 0 & -1 \end{bmatrix}$$

← בדו-ממד

← חד-ממד

Knowns as Sobel filters!

-1	-2	-1
0	0	0
1	2	1

-1	0	1
-2	0	2
-1	0	1



Aspect	Sobel Filter	Prewitt Filter
Filter Kernels	Uses specific 3x3 kernels for horizontal and vertical edges	Also uses 3x3 kernels for horizontal and vertical edges
Sensitivity to Intensity Changes	Slightly more emphasis on the central pixel in the kernel	Uniform weight to all pixels in the kernel
Edge Emphasis	Emphasizes diagonal edges slightly more	Provides a more uniform emphasis on vertical and horizontal edges


נגזרות ראשונות – ללא רעשים – המקרה הבדיד

1	0	0	1
0	-1	-1	0

יש גם גירסה של 45 מעלות

עוד משהו קטן לפני סוף חזרה..

Emboss Kernel: stylin'





עיבוד תמונה – שיעור 4 (שבוע 4)


- | | |
|-----------------------------------|-----------------------------|
| 1. חזרה | 2. שיעור 4 (שבוע 4) |
| 2. Convolutions \ קונבולציה | 1. נגזרת שניה ? צריך ? |
| 1. הגדרה | 2. נגזרת שניה. |
| 2. דוגמאות ראשונות | 3. לאפלאסיאן |
| 3. מה עושים עם קונבולציה – חלק א' | 4. דוגמא נגזרת ראשונה ושניה |
| 1. Blur | 5. נגזרת שניה עם רעש |
| 1. אחיד | 6. Marr–Hildreth algorithm |
| 2. גאוסיאני | 7. שימושים לנגזרת שניה |
| 3. Bi-lateral filter | 1. חידוד |
| 2. Edges | 8. סיכום |
| 1. First derivative | |
| 3. Blur + Edges | |

Finding edges


- Could take derivative
- Find high responses
- Sobel filters!
- But...



$f(x)$




$f'(x)$





Finding edges


- Could take derivative
- Find high responses
- Sobel filters!
- But...
- Edges go both ways
- (1) Want to find extrema ?



Finding edges

- Could take derivative
- Find high responses
- Sobel filters!
- But...
- Edges go both ways
- Want to find extrema?
- (2) Where exactly is the edge ?







No gradient




small gradient



high gradient



mid gradient



עיבוד תמונה – שיעור 4 (שבוע 4)



1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	

הפתרון ל 2 הבעיות, ועוד...

נגזרת שניה!

2nd derivative!

- Crosses zero at extrema




נגזרת שנייה

נגזור פעם
נוספת ונקבל:

$$\frac{\partial f}{\partial x} \approx f(x+1, y) - f(x, y)$$

$$\frac{\partial f}{\partial y} \approx f(x, y+1) - f(x, y)$$





$$\frac{\partial^2 f}{\partial x^2} \approx f(x+2, y) - 2f(x+1, y) + f(x, y)$$

$$\frac{\partial^2 f}{\partial y^2} \approx f(x, y+2) - 2f(x, y+1) + f(x, y)$$

2nd derivative as convolution filter

- כמו שראינו שניתן לקבל נגזרת ראשונה של תמונה בעזרת קנבולוציה. כך גם בניגרת שניה.



עיבוד תמונה – שיעור 4 (שבוע 4)

1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	

Laplacians



- Laplacian:

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Also known as
אופרטור הלפלאסיאן:

הנגזרת השנייה בעיבוד תמונה מכונה לעיתים קרובות "לפלאסיאן" מכיוון שהיא מחושבת באמצעות אופרטור המכונה "האופרטור הלפלאסי". האופרטור "לפלאסיאן" הוא אופרטור מתמטי שמחשב את סכום הנגזרות המרחביות השניות של תמונה.

- Measures the divergence of the gradient
 - Flux of gradient vector field through small area



Laplacians

- Laplacian:


$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

$$\left(\begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix} * \begin{array}{|c|} \hline \\ \hline \end{array} \right) + \left(\begin{bmatrix} 1 & -2 & 1 \end{bmatrix} * \begin{array}{|c|} \hline \\ \hline \end{array} \right)$$

Laplacians

- Laplacian:


$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$



Laplacians

- Laplacian:


$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$



Laplacians

- Laplacian:

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$



Laplacians



- Laplacian:

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

- .Negative Laplacian, -4 in middle


0	1	0
1	-4	1
0	1	0

*




עיבוד תמונה – שיעור 4 (שבוע 4)


1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	




Original Image




First Derivative X









First Derivative Y



Second Derivative (Laplacian)






compare_first_n_second_derivative.py




Menti ?


21	0	0	0
22	0	0	0
23	6	6	6
24	40	40	40
25	128	128	128
26	215	215	215
27	249	249	249
28	255	255	255
29	255	255	255
30	255	255	255
31	255	255	255
32	255	255	255
33	255	255	255




	0	0	6	40	128	215	249	255	255	255	255	255
	0	0	6	40	128	215	249	255	255	255	255	255
	0	0	6	40	128	215	249	255	255	255	255	255
21	0	0	6	40	128	215	249	255	255	255	255	255
22	0	0	6	40	128	215	249	255	255	255	255	255
23	0	0	6	40	128	215	249	255	255	255	255	255
24	0	0	6	40	128	215	249	255	255	255	255	255
25	0	0	6	40	128	215	249	255	255	255	255	255
26	0	0	6	40	128	215	249	255	255	255	255	255
27	0	0	6	40	128	215	249	255	255	255	255	255
28	0	0	6	40	128	215	249	255	255	255	255	255
29	0	0	6	40	128	215	249	255	255	255	255	255
30	0	0	6	40	128	215	249	255	255	255	255	255
31	0	0	6	40	128	215	249	255	255	255	255	255
32	0	0	6	40	128	215	249	255	255	255	255	255
33	0	0	6	40	128	215	249	255	255	255	255	255



÷ 21	÷ 22	÷ 23	÷ 24	÷ 25	÷ 26	÷ 27	÷ 28	÷ 29
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0
0.0	24.0	160.0	488.0	700.0	484.0	160.0	24.0	0.0



÷ 21	÷ 22	÷ 23	÷ 24	÷ 25	÷ 26	÷ 27	÷ 28	÷ 29
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000
0.00000	6.00000	28.00000	54.00000	-1.00000	-53.00000	-28.00000	-6.00000	0.00000



עיבוד תמונה – שיעור 4 (שבוע 4)

1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	

נגזרת שניה עם רעש

Laplacians



- Laplacian:

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

- .Negative Laplacian, -4 in middle


0	1	0
1	-4	1
0	1	0

*




Laplacians also sensitive to noise


- Again, use gaussian smoothing
- Can just use one kernel since convs commute
- Laplacian of Gaussian, LoG
- Can get good approx. with 5x5 - 9x9 kernels



לפליסיאן של גאוסיאן (LOG)

$$L^*(G^* f) = (L^* G)^* f = (\nabla^2(G))^* f$$





$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$\nabla^2 G(x, y) = -\frac{1}{\pi\sigma^4} \left(1 - \frac{x^2 + y^2}{2\sigma^2} \right) e^{-\frac{x^2+y^2}{2\sigma^2}}$$

LOG.py

```
sigma = 1.0
# Define the kernel size
k = 2 * np.ceil(3 * sigma).astype(int) + 1


# Create a Gaussian kernel
x = np.arange(-k // 2 + 1., k // 2 + 1.)
y = np.arange(-k // 2 + 1., k // 2 + 1.)

x, y = np.meshgrid(x, y)
gaussian_kernel = np.exp(-(x**2 + y**2) / (2. * sigma**2)) / (2. * np.pi * sigma**2)
gaussian_kernel = gaussian_kernel / np.sum(gaussian_kernel)


# Create a Laplacian kernel
laplacian_kernel = np.array([[0, 1, 0], [1, -4, 1], [0, 1, 0]])

# Convolve the Gaussian kernel with the Laplacian kernel
log_kernel = convolve2d(gaussian_kernel, laplacian_kernel, mode='same')

# Plot the LoG kernel
plt.imshow(log_kernel, cmap='gray')
plt.show()
```




2D edge detection filters




Gaussian

$$h_{\sigma}(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{u^2+v^2}{2\sigma^2}}$$



derivative of Gaussian

$$\frac{\partial}{\partial x} h_{\sigma}(u, v)$$



Laplacian of Gaussian

$$\nabla^2 h_{\sigma}(u, v)$$

∇^2 is the **Laplacian** operator:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

ו"בחיים עצמם"....

בדומה לסובול – זה פשוט השימוש הסטדנרטי. "לא שואלים" אם יש
רעש או אין – פשוט משתמשים בזה.
(ולרוב מנקים את התמונה עוד לפני...)

Laplacian of Gaussian, LoG

-1	2	-1
2	-4	2
-1	2	-1

עיבוד תמונה – שיעור 4 (שבוע 4)

- | | |
|-----------------------------------|-----------------------------|
| 1. חזרה | 2. שיעור 4 (שבוע 4) |
| 2. Convolutions \ קונבולציה | 1. נגזרת שניה ? צריך ? |
| 1. הגדרה | 2. נגזרת שניה. |
| 2. דוגמאות ראשונות | 3. לאפלאסיאן |
| 3. מה עושים עם קונבולציה – חלק א' | 4. דוגמא נגזרת ראשונה ושניה |
| 1. Blur | 5. נגזרת שניה עם רעש |
| 1. אחיד | 6. Marr–Hildreth algorithm |
| 2. גאוסיאני | 7. שימושים לנגזרת שניה |
| 3. Bi-lateral filter | 1. חידוד |
| 2. Edges | 8. סיכום |
| 1. First derivative | |
| 3. Blur + Edges | |


Marr–Hildreth algorithm



1. ****החלקת התמונה****: תחילה, מנקים את התמונה באמצעות פילטר גאוס, כדי להפחית רעש. זה עוזר להבטיח שהקצוות שנמצאים הם 'אמיתיים' ולא תוצאה של רעש בתמונה.
 2. ****חישוב הגרדיאנטים****: לאחר הניקוי, האלגוריתם מחשב את גרדיאנט התמונה - כלומר, את מידת השינוי בבהירות בכל נקודה בתמונה. הגרדיאנטים מצביעים על כיוון השינוי החד ביותר בבהירות, שם סביר למצוא קצוות.
 3. ****מציאת edge****: לבסוף, האלגוריתם מזהה את edge על ידי מציאת המקומות בהם הגרדיאנט של התמונה חוצה את אפס. זה נעשה באמצעות חישוב הלפלסיאן של התמונה (הנגזרת השנייה של התמונה) ואז מציאת הנקודות בהן הלפלסיאן חוצה את אפס. נקודות אלו מסומנות כקצוות.
- האלגוריתם של **Marr–Hildreth** מאפשר זיהוי edge בתמונה באופן יחסית פשוט ויעיל, והוא שימש כבסיס לפיתוח שיטות מתקדמות יותר לגילוי קצוות בתחום עיבוד התמונה.

Special Patches in 1D



How does an edge look in 1D?






Here! Look! Extrema!


Finding zero crossings is much easier than finding extrema because it's a local property!

Consider a 3x3 patch:



zero crossing!

If at least one pixel has a Laplacian of different sign than the Laplacian of the center pixel, then a zero crossing occurred!




תוצאות עדיין לא מרשימות בתמונה רועשת... 7 טבעית


עיבוד תמונה – שיעור 4 (שבוע 4)

1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	

סיכום בינים

נגזרת ראשונה + שניה -- שימוש בנגזרות
== (תזכורת..חידוד)





עיבוד סיפרתי של תמונות: קצוות תמונה

```
import matplotlib.pyplot as plt


img = cv2.imread('pic1.PNG', 0)

filter_blured = cv2.GaussianBlur(img, (7, 7), 0)
alpha = 5
sharpened = img + alpha * (img - filter_blured)

images = [img, filter_blured, sharpened]
titles = ["Orig image", "GaussianBlur", "Sharpened"]

for i in range(3):
    plt.subplot(3, 1, i+1), plt.imshow(images[i], 'gray')
    plt.title(titles[i])
```

Sharpen Kernel: sharpens!




עיבוד סיפרתי של תמונות: קצוות תמונה


$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} - \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

Sharpen Kernel: sharpens!




Note: sharpen = highpass + identity!



In the final sharpened image edges and fine detail are much more obvious

This gives us a new filter which does the whole job for us in one step




There are lots of slightly different versions of the Laplacian that can be used:

0	1	0
1	-4	1
0	1	0


Simple
Laplacian

1	1	1
1	-8	1
1	1	1

Variant of
Laplacian



-1	-1	-1
-1	9	-1
-1	-1	-1



עיבוד תמונה – שיעור 4 (שבוע 4)

1. חזרה	2. שיעור 4 (שבוע 4)
2. Convolutions \ קונבולציה	1. נגזרת שניה ? צריך ?
1. הגדרה	2. נגזרת שניה.
2. דוגמאות ראשונות	3. לאפלאסיאן
3. מה עושים עם קונבולציה – חלק א'	4. דוגמא נגזרת ראשונה ושניה
1. Blur	5. נגזרת שניה עם רעש
1. אחיד	6. Marr–Hildreth algorithm
2. גאוסיאני	7. שימושים לנגזרת שניה
3. Bi-lateral filter	1. חידוד
2. Edges	8. סיכום
1. First derivative	
3. Blur + Edges	


סיכום

Filters

פילטר

0	-1	0
-1	5	-1
0	-1	0


תמונה



פילטר

0	0	0
0	1	0
0	0	0


תמונה



פילטר

-2	-1	0
-1	1	1
0	1	2

תמונה




Laplacian of Gaussian, LoG

-1	2	-1
2	-4	2
-1	2	-1

פילטר

-1	-2	-1
0	0	0
1	2	1


תמונה



פילטר

0	-1	0
-1	4	-1
0	-1	0


תמונה



פילטר

-1	0	1
-2	0	2
-1	0	1

תמונה



נגזרת שנייה	נגזרת ראשונה	
הנגזרת השנייה מספקת את השינוי של השינוי בערכי הצבע , כלומר מדגישה איפה "מהירות" שינוי הגרדיאנט (הצבע).	הנגזרת הראשונה מספקת את השינוי בערכי הצבע או הגרדיאנט של התמונה.	משמעות מושגית
רגישות פחותה לרעש.	רגישה במיוחד לרעש.	רגישות לרעש
מגלה מעברים מאפור לאפור כהה ומאפור לאפור בהיר בלי חישובים נוספים) (zero-crossings). הדבר מקנה לה יעילות גבוהה יותר בגילוי פרטים עדינים וקווים חיצוניים.	מספקת מידע על הכיוון של המעבר בגווני האפור (מבהיר לכהה או להפך) ויכולה לגלות קצוות, אך עשויה לפספס פרטים עדינים מסוימים.	גילוי קצוות
משמשת בטכניקות גילוי קצוות מתקדמות יותר כמו המסננים Laplacian ו-Marr-Hildreth.	משמשת בטכניקות גילוי קצוות כמו Prewitt, Sobel ו-Roberts.	שימושים
משמשת גם באלגוריתמים לגילוי מאפיינים כמו Scale-Invariant Feature Transform (SIFT) לזיהוי ותיאור מאפיינים מקומיים בתמונות.	משמשת גם בגילוי תנועה לקביעת התזוזה בין שתי פריסות בסרטון.	
אפשרות השימוש בשיטת ה- Laplacian of Gaussian (LoG) משלבת חלקה גאוסיאנית עם אופרטור ה- Laplacian כדי להפחית את הרעש ולגלות קצוות.	דורשת שימוש בטכניקות ניקוי או הפחתת רעש נוספות לפני או במהלך העיבוד על מנת להפחית את ההשפעה של הרעש.	הפחתת רעש

קירוב של LoG

Laplacian of Gaussian, LoG

-1	2	-1
2	-4	2
-1	2	-1


זה DoG

- Can be approximated by a difference of two Gaussians (DoG)


$$\nabla^2 G_\sigma \approx G_{\sigma_1} - G_{\sigma_2}$$

Best approximation when:

$$\sigma_1 = \frac{\sigma}{\sqrt{2}}, \sigma_2 = \sqrt{2}\sigma$$




1D example




Difference of Gaussian (DoG)

$$- \quad g(\sigma_1) * I - g(\sigma_2) * I = [g(\sigma_1) - g(\sigma_2)] * I$$



DoG (1 - 0)



DoG (2 - 1)




DoG (3 - 2)



DoG (4 - 3)






תרגיל כיתה


- חלק א - יצרו את התמונה הבאה (גודל 150 על 150)

– כל תת מלבן הוא בגודל 50 על 50:



- חלק ב'. קראו את התמונה מחלק א' כקלט. ותוך שימוש בכלים שלמדנו עד כה בקורס זה בלבד סמנו את הפינות האדומות.

– כלומר הפלט של התרגיל תמונת המשבצות
כאשר אתן מסמנות ומצירות את הנקודות באדום



תרגיל כיתה

- חלק ג' – חשבו את השטח של כל תת מלבן כאשר הקלט הוא התמונה בלבד.
- חלק ד' תמונה חדשה – חשבו את השטח של האות |

